Advance Study Group

Regresi Linear

Least Squares

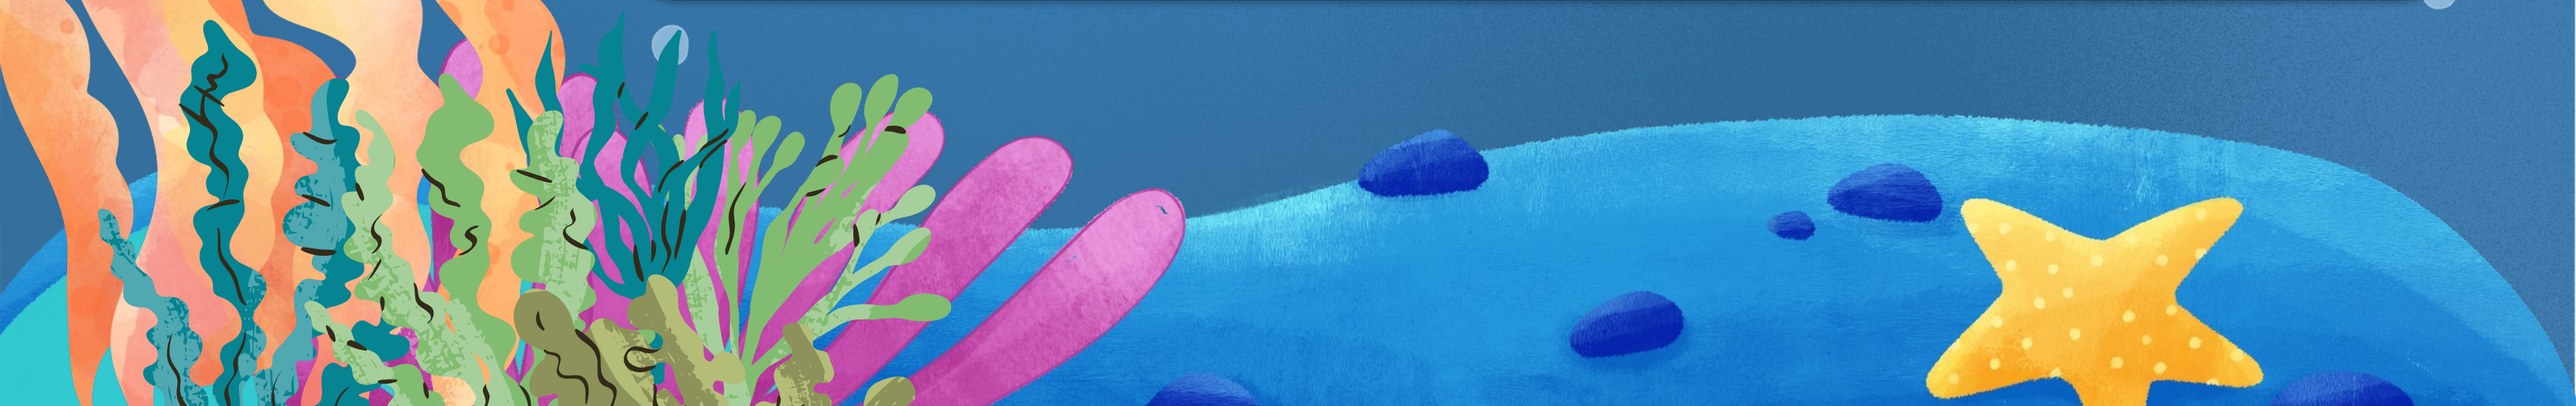
Pertemuan 1



Agenda Hari Ini

0:00	Masalah: tarif Go-car (10 menit)
0:10	Garis mana yang paling cocok? RSS (15)
0:25	Menurunkan rumus least squares (25)
0:50	Latihan 1 sampai 3 di kertas (25)
1:15	Latihan 4 dan 5 di Colab (30)
1:45	Diskusi dan Pekan 2 (15)





MASALAH

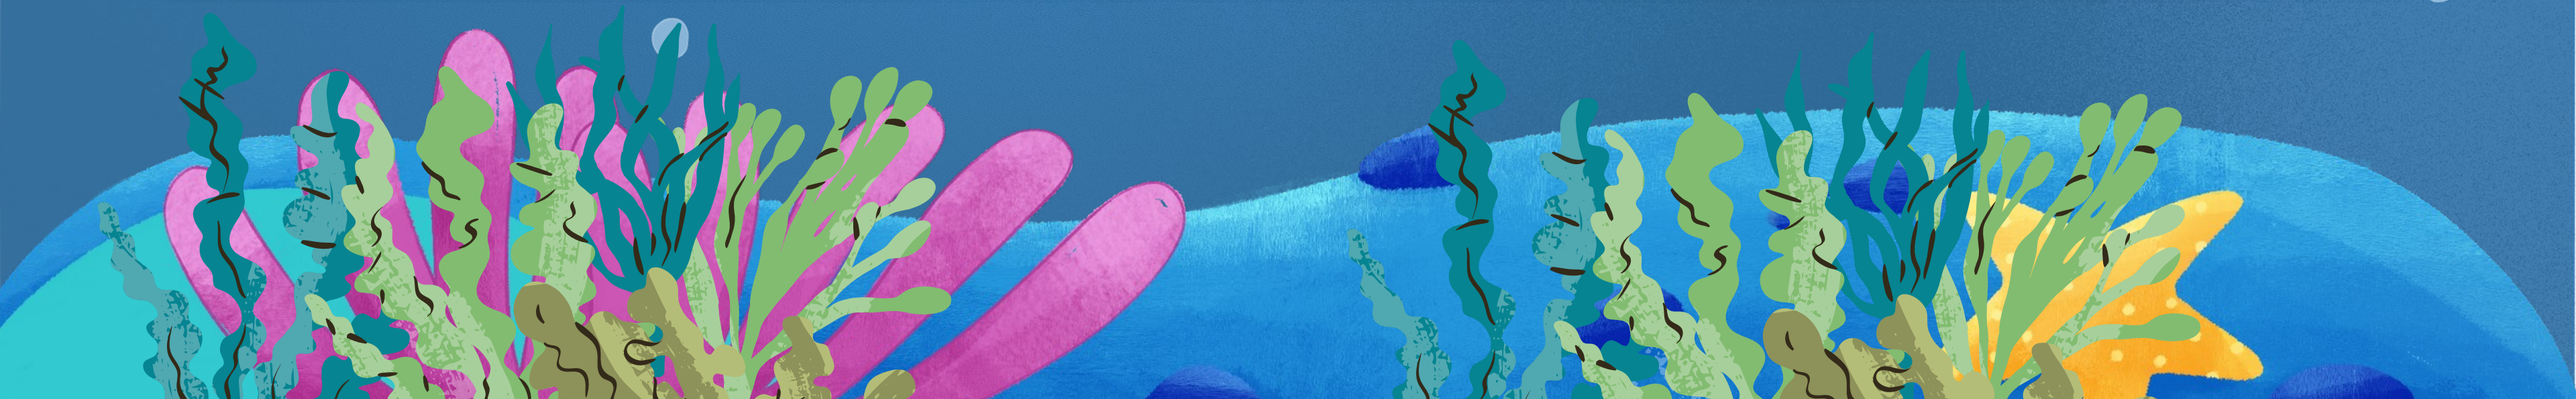
Berapa tarif Go-car bulan depan?

- JalanJalan adalah perusahaan travel yang sering memakai Go-car untuk mengantar tamu.
- Mereka harus menyusun anggaran bulanan, jadi tarif harus diperkirakan jauh hari sebelumnya.
- Mereka punya catatan tarif dari perjalanan sebelumnya.

Pertanyaan

Bagaimana membuat model dari data historis untuk memprediksi tarif?

Contoh Go-car: Dr. Didit Adytia, S.Si., M.Si., mata kuliah Machine Learning, Informatika Telkom University



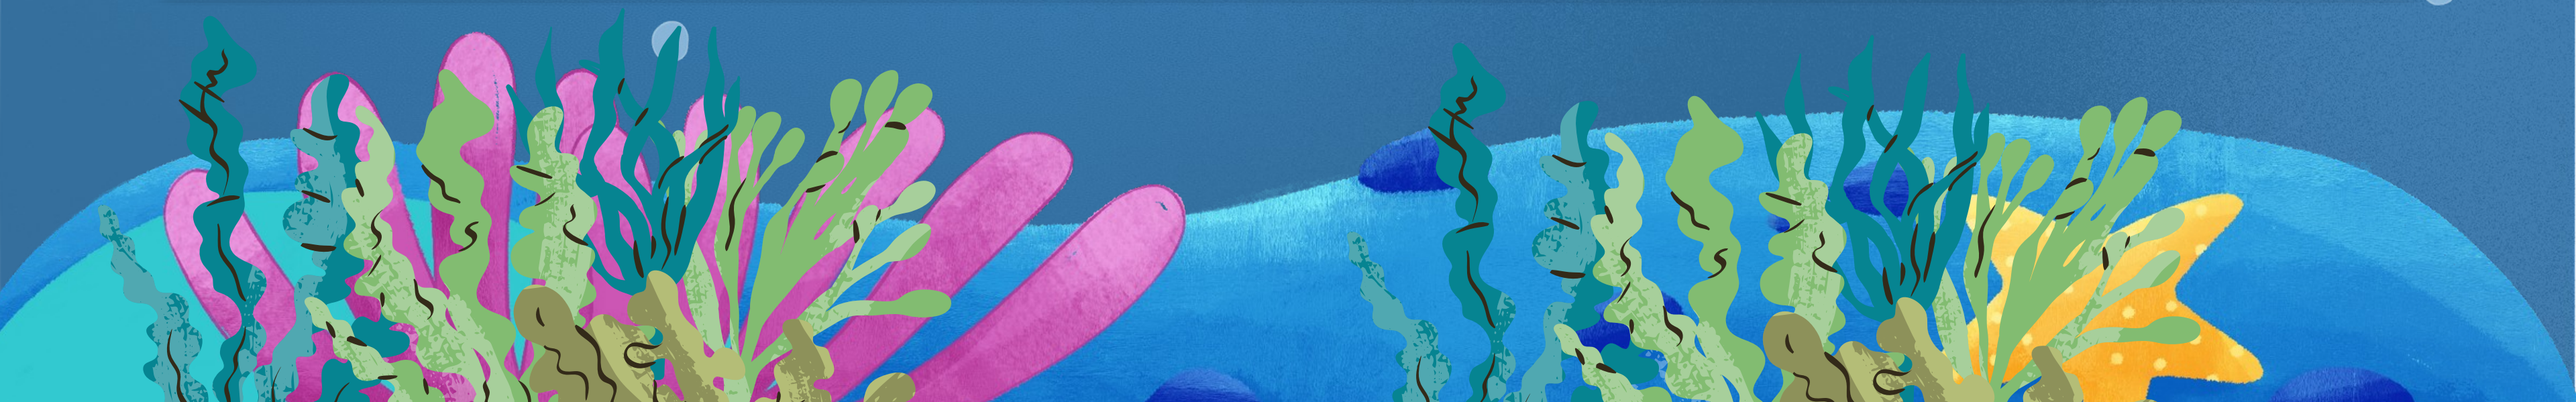
DATA

15 perjalanan Go-car

No	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
km	5	5	6	6	8	8	9	9	10	11	11	12	12	12	13
Tarif (ribu Rp)	28,6	40,1	32,6	38,6	49,7	46,1	55,3	49,8	58,7	67,7	72,6	79,8	72,4	70,6	70,7

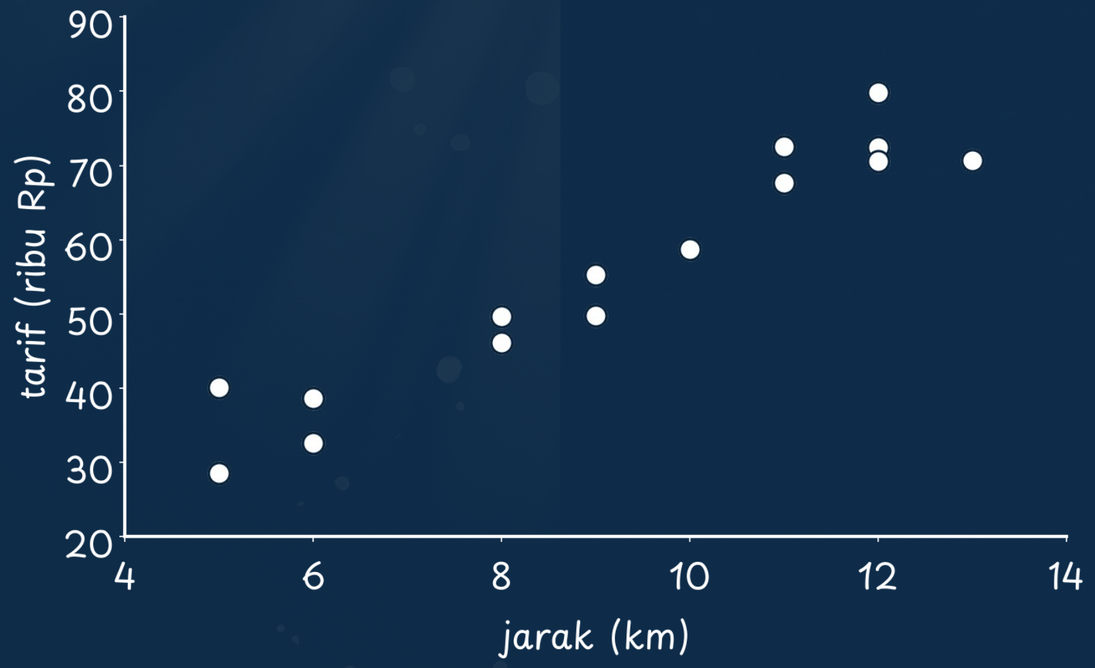
Satu kolom = satu perjalanan: jarak dalam km, tarif yang benar-benar dibayar.

Apa yang bisa kita lakukan dengan data ini?



DATA

Kalau digambar



Apa polanya?

Makin jauh, makin mahal.

Titik-titiknya hampir membentuk garis lurus yang naik: hubungan positif.

MODEL

Modelnya: sebuah garis

$$f(x) = w\,x + a$$

w kemiringan (slope): tambahan tarif untuk setiap 1 km

a titik potong (intercept): tarif saat jarak 0

$\hat{y}_i$ prediksi model untuk perjalanan ke-i

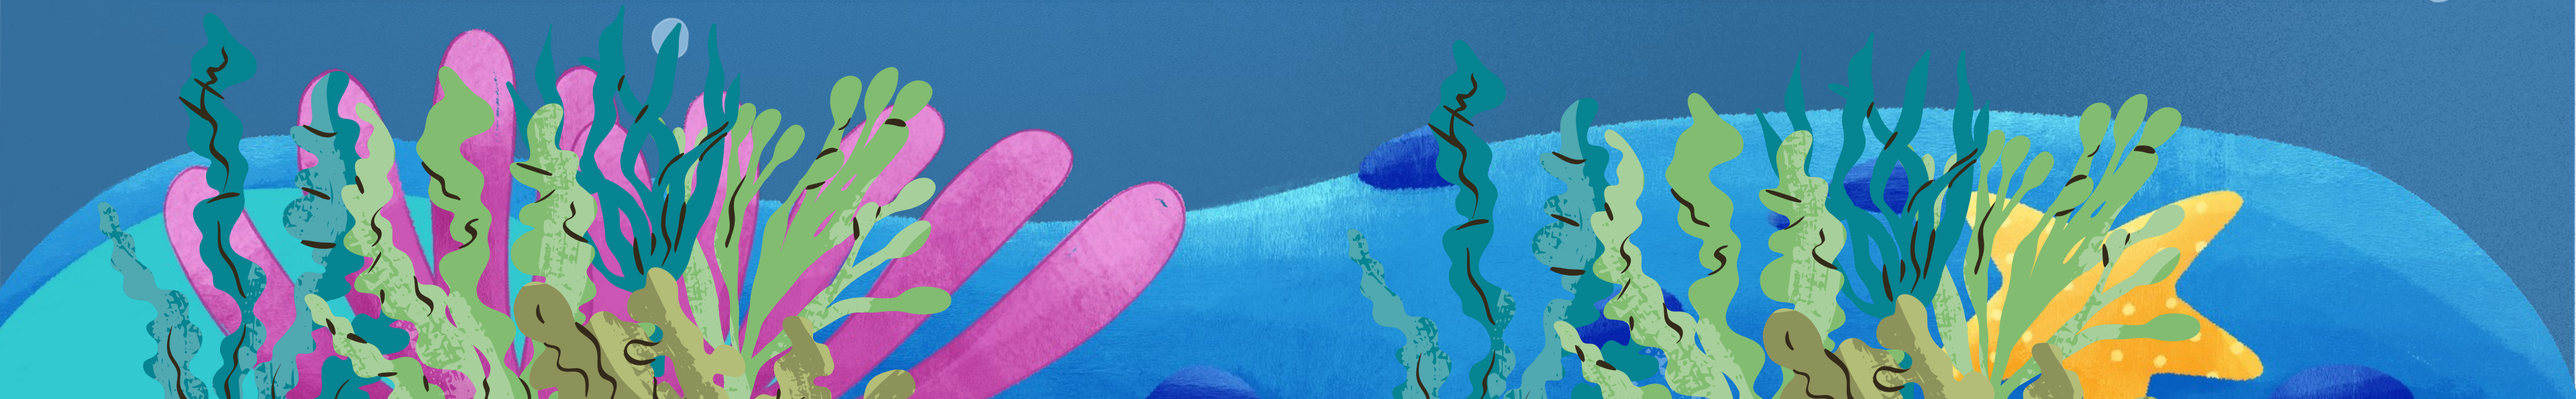
y_i tarif sebenarnya dari data

Catatan notasi

Di Pekan 0 kita menulis tarif = a × jarak + b.

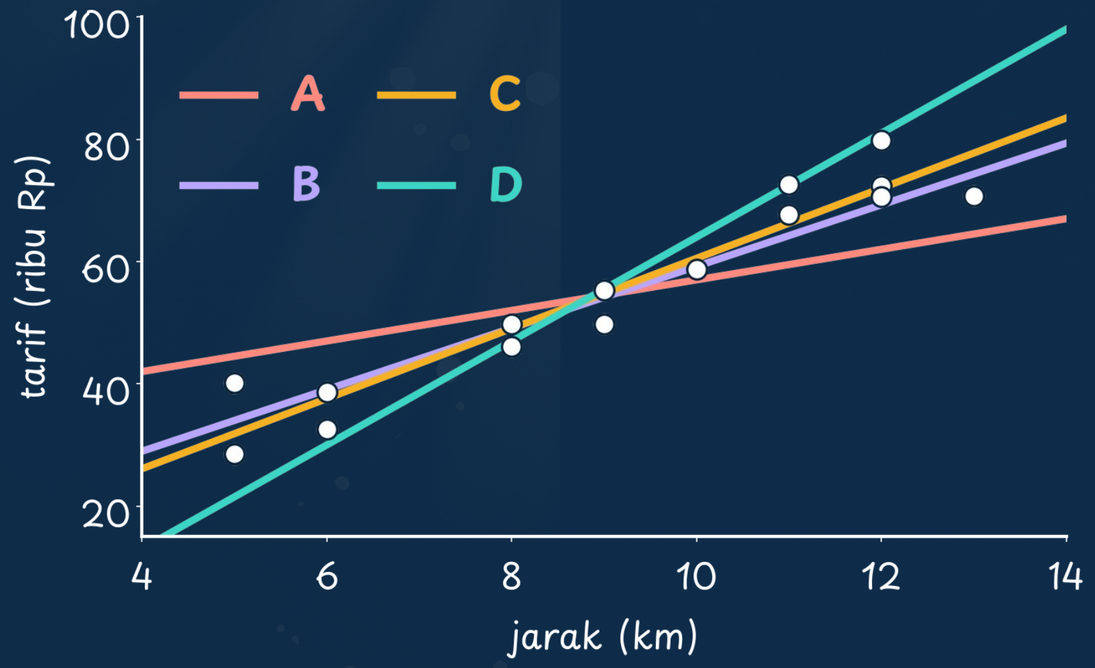
Mulai hari ini kita memakai notasi mata kuliah Machine Learning:

w = kemiringan, a = titik potong



PERTANYAAN

Garis mana yang paling cocok?



Empat garis, empat pilihan w dan a

Angkat tangan: A, B, C, atau D?

Apa alasanmu?

MOTIVASI

Kita bisa melihat. Komputer tidak.

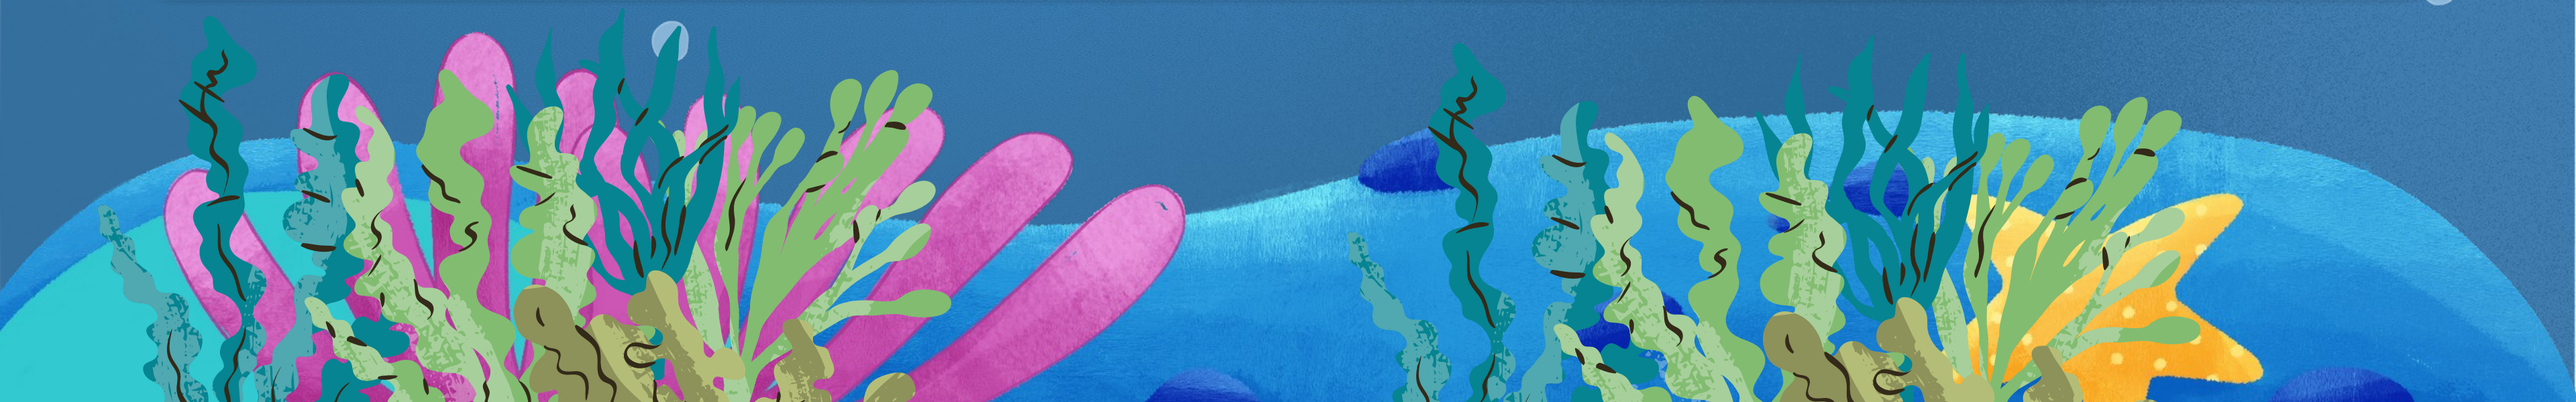
Manusia

Kita langsung merasa garis mana yang pas. Tapi saat B dan C hampir sama, perasaan saja tidak cukup.

Komputer

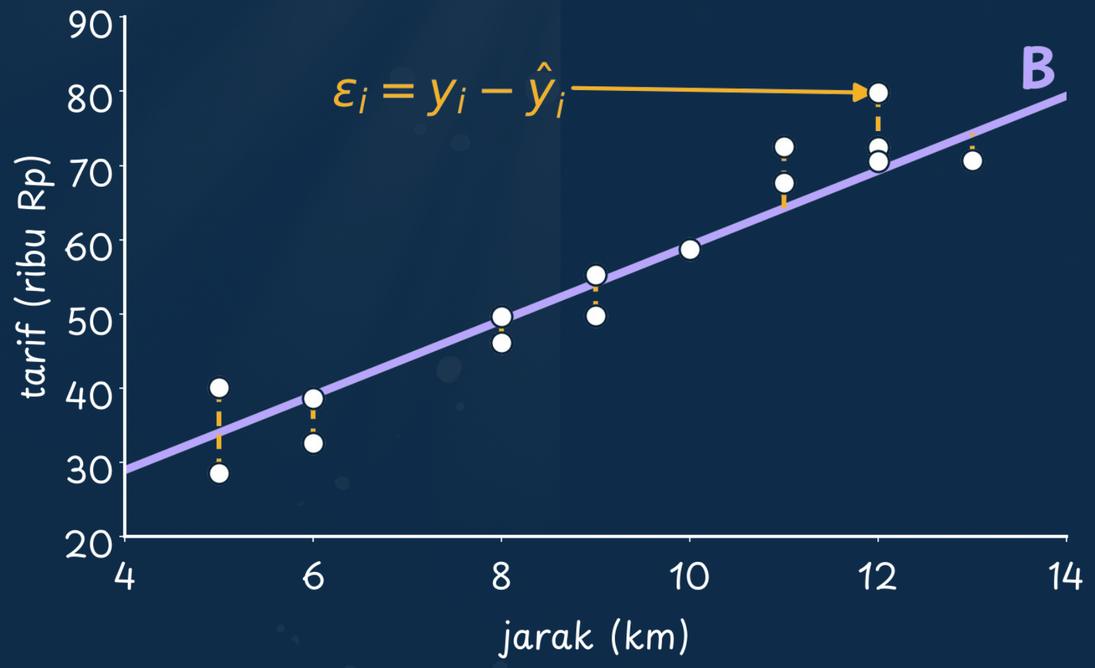
Komputer tidak bisa melihat gambar. Ia hanya bisa menghitung.

Jadi kita perlu satu angka yang mengukur seberapa tidak cocok sebuah garis dengan data.



ERROR

Mulai dari satu titik



$$\varepsilon_i = y_i - \hat{y}_i$$

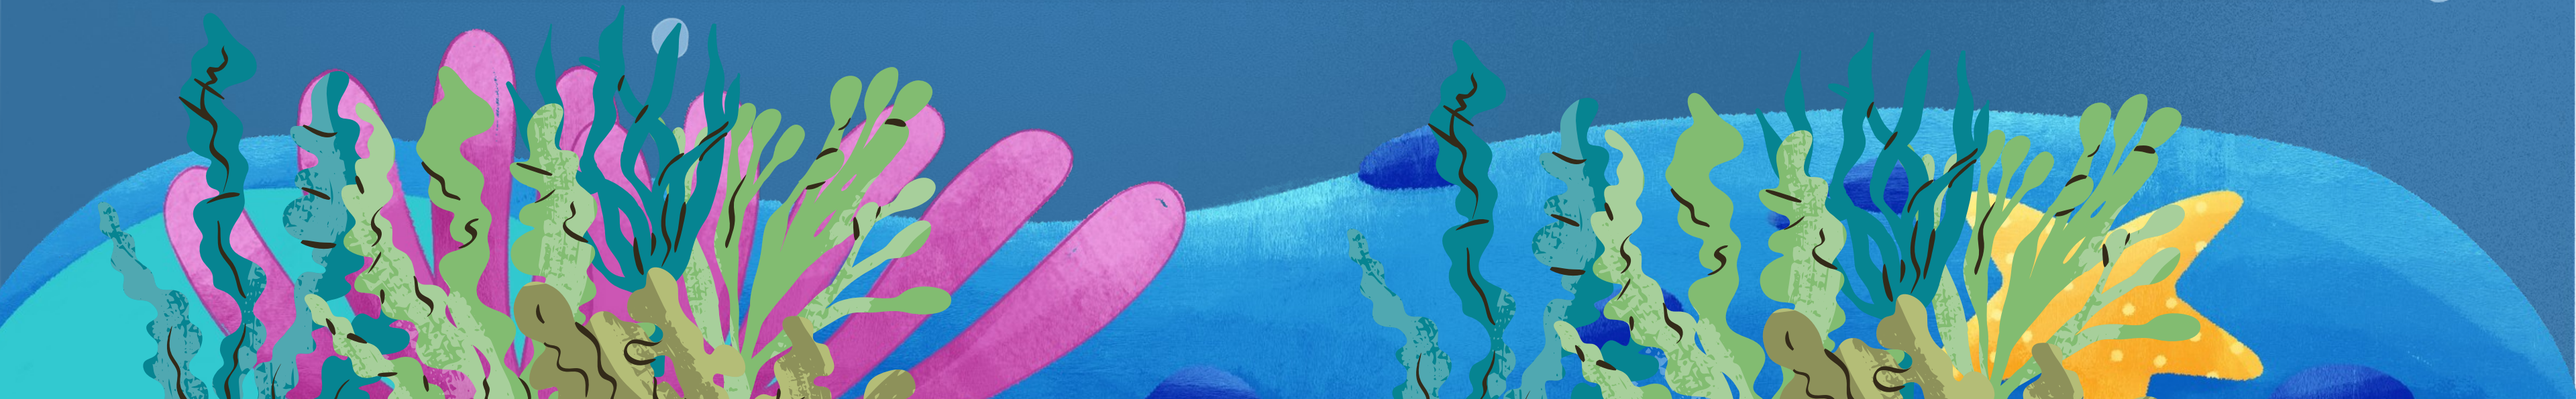
- Error (residual): jarak tegak antara data dan garis
- Positif jika data di atas garis, negatif jika di bawah
- Dijumlah begitu saja, yang positif dan negatif saling menghapus
- **Solusinya: kuadratkan setiap error, baru dijumlah**

Residual Sum of Squares (RSS)

$$\mathrm{RSS}(w, a) = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} (y_i - w\,x_i - a)^2$$

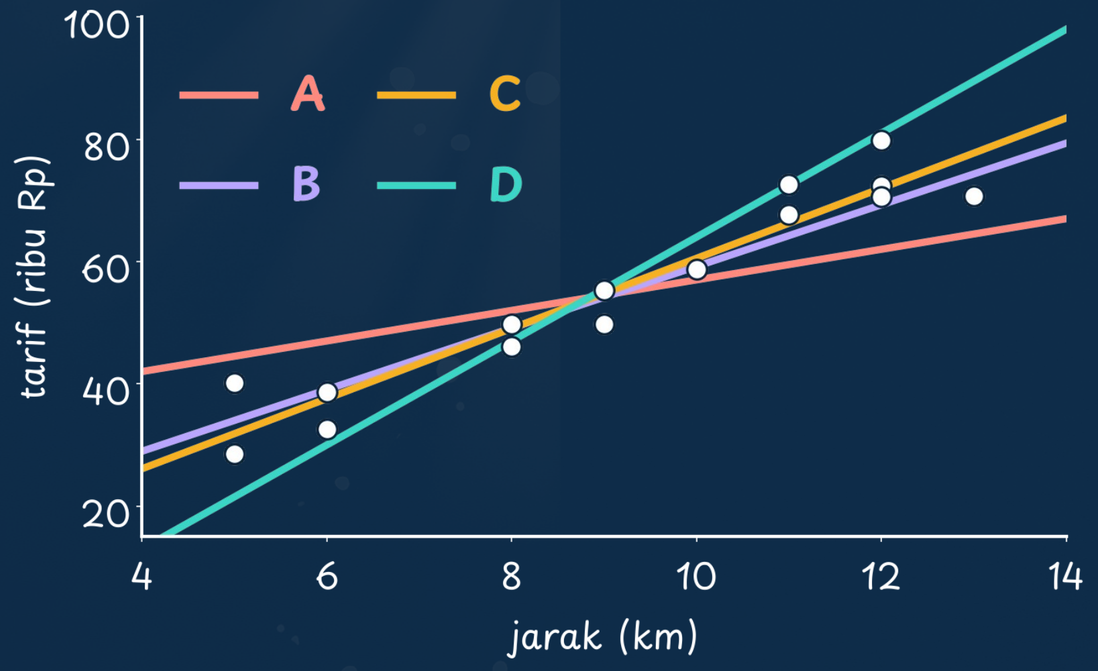
Satu garis, satu angka

Setiap pasangan w dan a menghasilkan satu nilai RSS. Semakin kecil, semakin cocok garisnya. Di materi kuliah, ukuran ini juga disebut SSE (sum of squared errors).



JAWABAN

Sekarang komputer bisa memilih



Garis	RSS (juta)
A	1.392,1
B	355,2
C	296,9
D	1.105,9

C menang, walaupun B dan C hampir sama di mata kita.

Tapi apakah ada garis lain yang lebih baik dari C?

OPTIMASI

Menjadi masalah optimasi

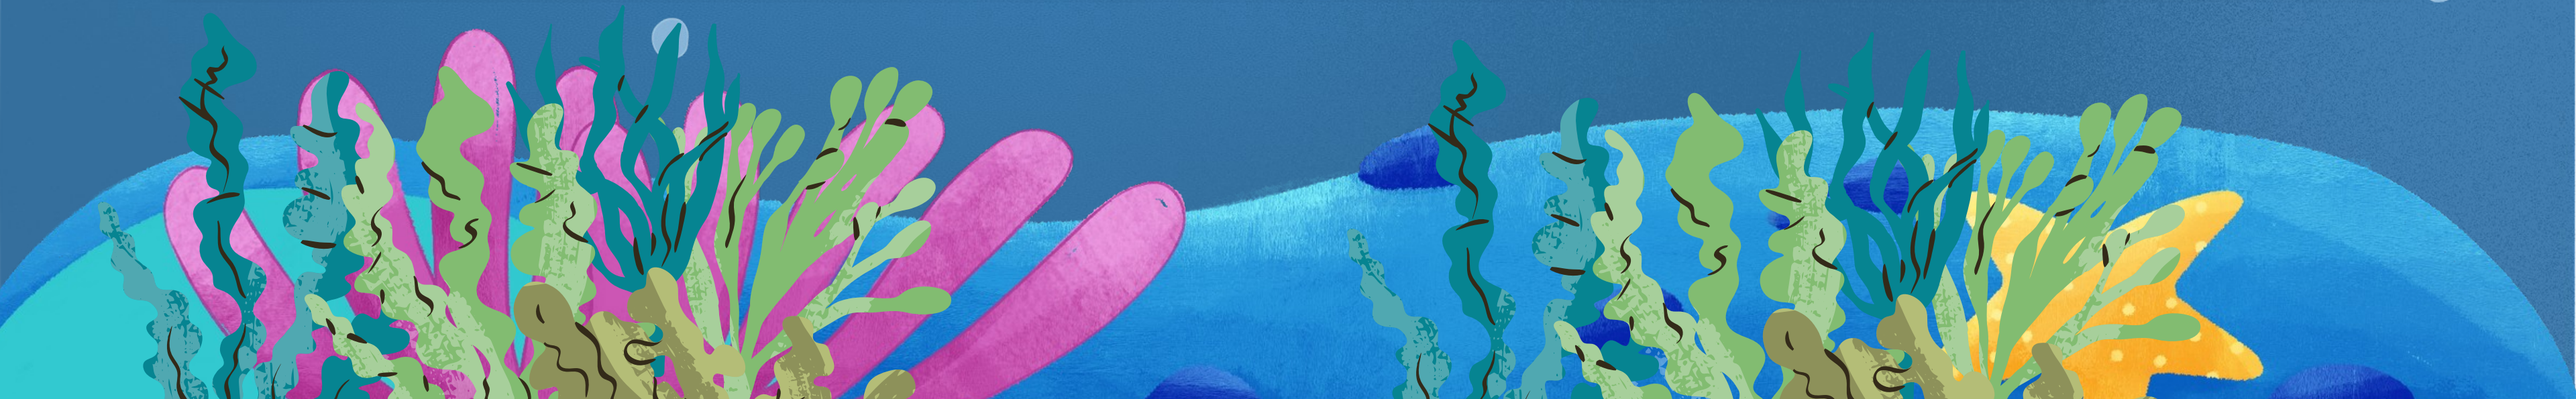
$$\min_{w,\,a} \; \mathrm{RSS}(w, a)$$

Variabel keputusan
w dan a

Fungsi tujuan
RSS(w, a)

Batasan
tidak ada: w dan a boleh bernilai berapa saja

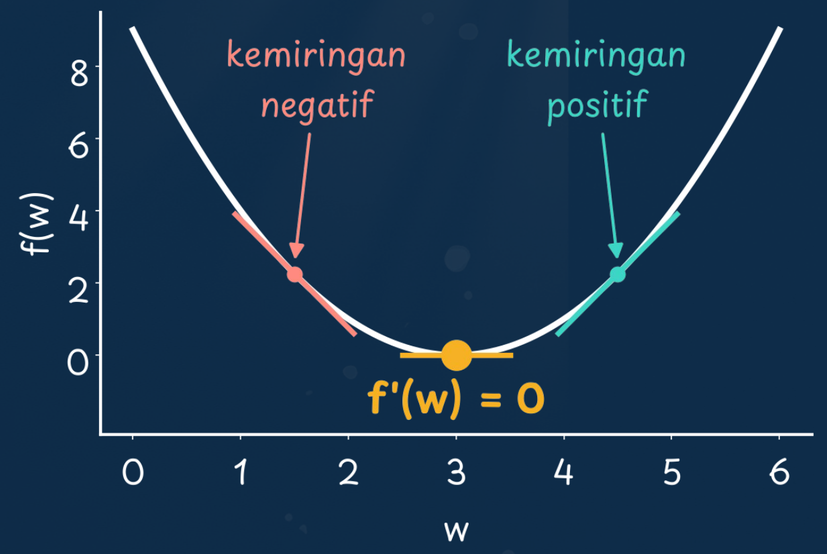
Dari semua garis yang mungkin, cari w dan a dengan RSS terkecil. Untuk garis lurus, kalkulus memberi jawabannya secara pasti.



INTERMEZZO

Di titik terendah, kemiringannya nol

$$f(w) = (w-3)^2 \quad \Rightarrow \quad f'(w) = 2(w-3) = 0 \quad \Rightarrow \quad w = 3$$



- Turunan adalah kemiringan kurva
- Di *dasar lembah*, kemiringannya nol
- **Dua variabel? Turunan parsial: turunkan terhadap satu variabel, anggap yang lain konstanta**
- Aturan rantai: turunan dari u^2 adalah $2u \cdot u'$

LANGKAH 1

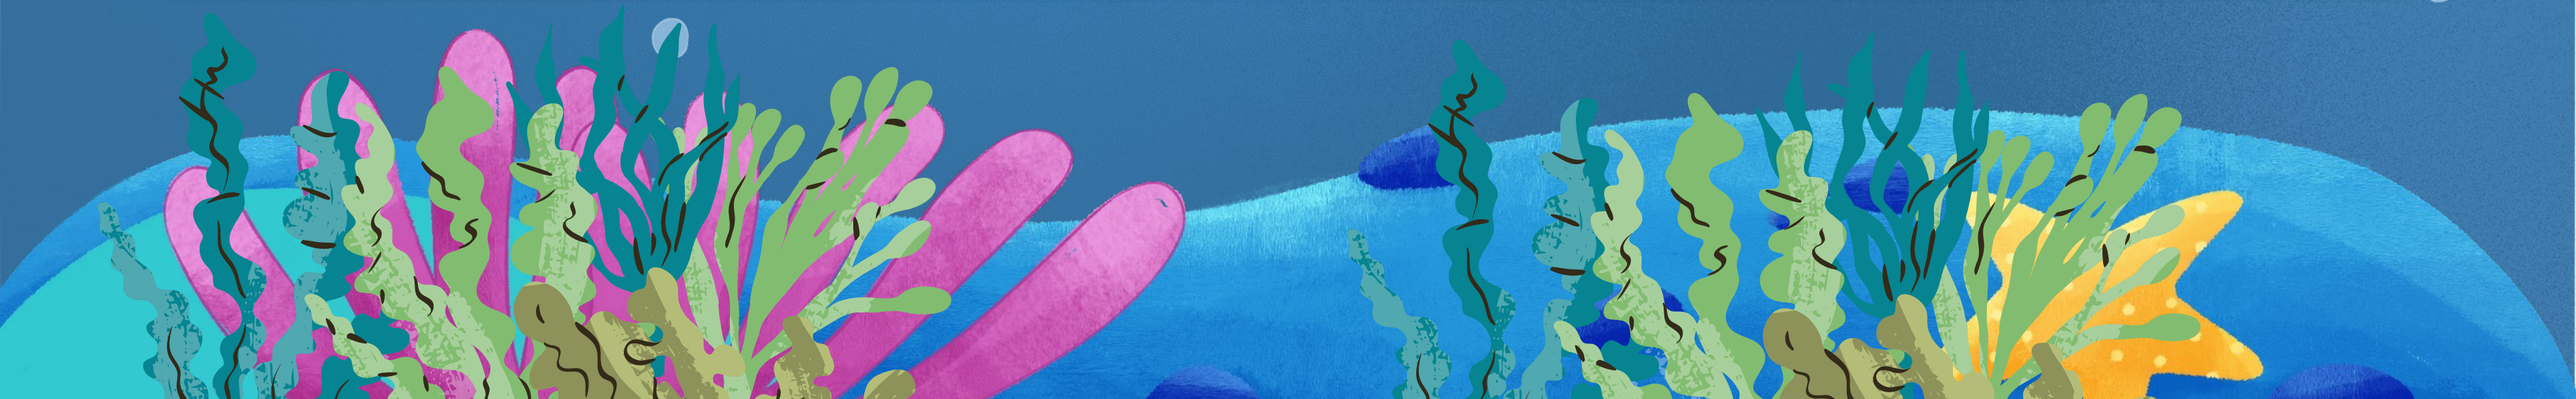
Turunan terhadap a: giliranmu

$$\mathrm{RSS}(w, a) = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} (y_i - w\,x_i - a)^2$$

$$\frac{\partial\,\mathrm{RSS}}{\partial a} = \ ?$$

3 menit, berpasangan

Turunkan RSS terhadap a. Anggap w, x_i, dan y_i sebagai konstanta. Petunjuk: aturan rantai, dan turunan dari $(y_i - w{\cdot}x_i - a)$ terhadap a adalah −1.



LANGKAH 1

Turunan terhadap a

$$\frac{\partial \text{RSS}}{\partial a} = \sum \frac{\partial}{\partial a} (y_i - w x_i - a)^2$$

turunan dari sebuah jumlah adalah jumlah dari turunannya

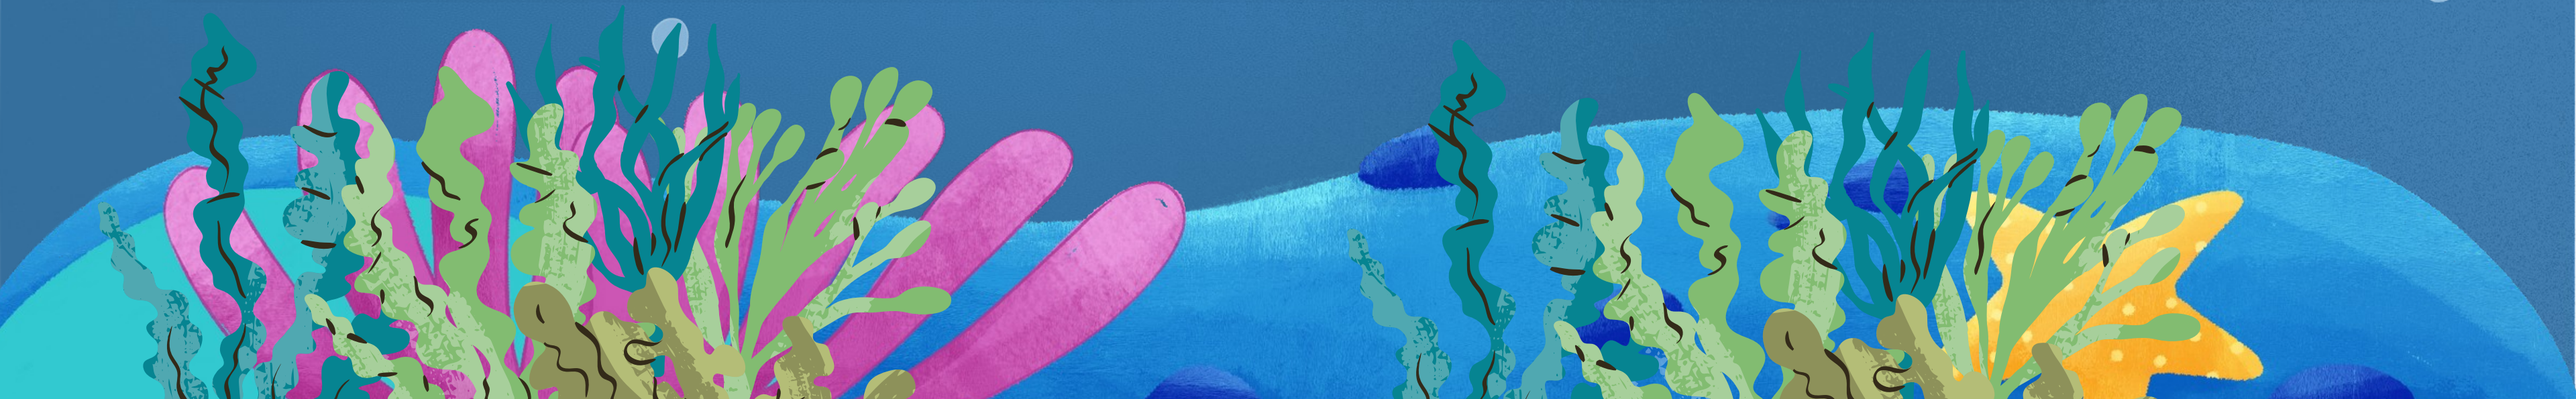
$$= \sum 2 (y_i - w x_i - a) \cdot (-1)$$

aturan rantai: turunan u^2 adalah $2u \cdot u'$, dan turunan $(y_i - w \cdot x_i - a)$ terhadap a adalah -1

$$= -2 \sum (y_i - w x_i - a)$$

keluarkan konstanta -2 dari jumlah

Semua Σ berarti jumlah dari i = 1 sampai n.



LANGKAH 1

Samakan dengan nol, selesaikan untuk a

$$-2\sum(y_i - w\,x_i - a) = 0$$

di titik minimum, turunannya nol

$$\sum y_i - w\sum x_i - \sum a = 0$$

bagi kedua ruas dengan −2, lalu pecah jumlahnya

$$\sum y_i - w\sum x_i - n\,a = 0$$

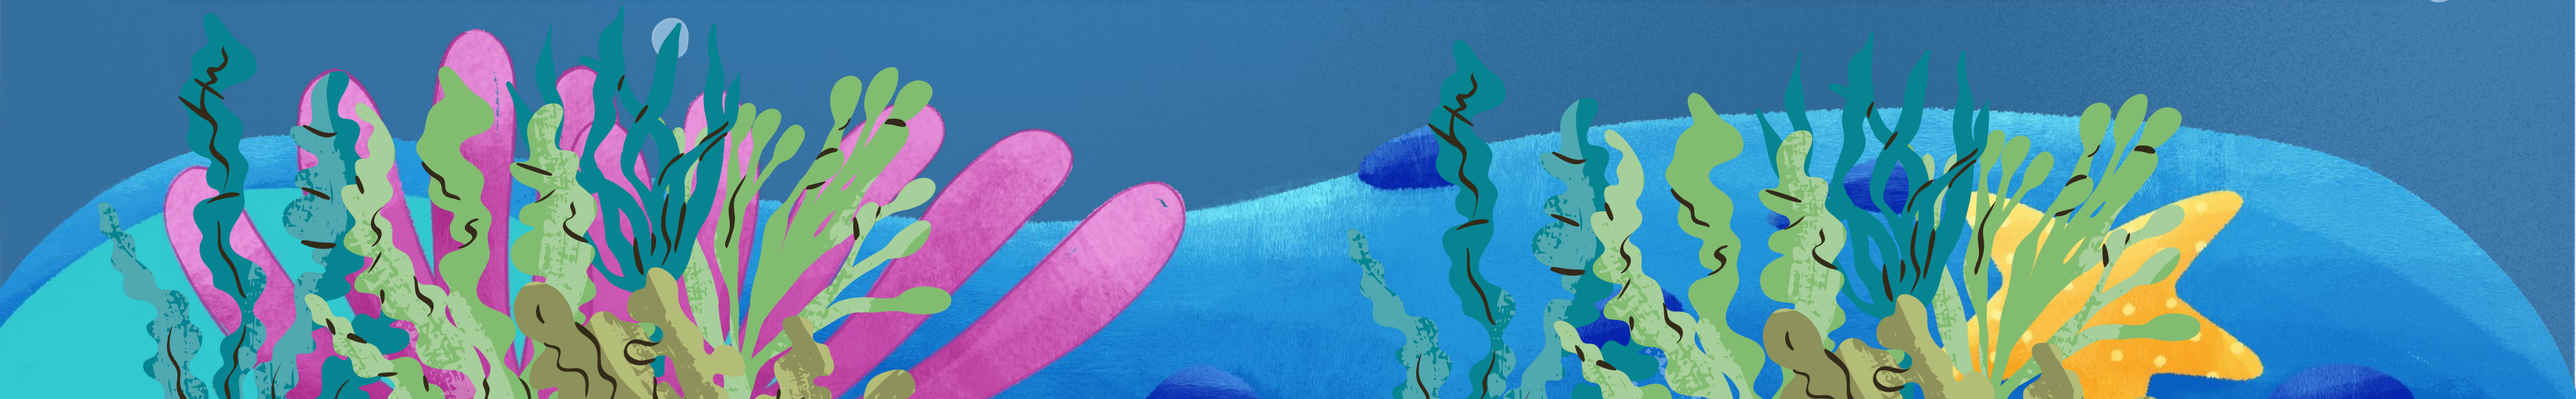
a tidak bergantung pada i, jadi $\Sigma a = n \cdot a$

$$\bar{y} - w\,\bar{x} - a = 0$$

bagi dengan n: $(1/n)\cdot\Sigma y_i$ adalah rata-rata y, $(1/n)\cdot\Sigma x_i$ adalah rata-rata x

$$\hat{a} = \bar{y} - w\,\bar{x}$$

persamaan (4)



LANGKAH 2

Turunan terhadap w

$$\frac{\partial RSS}{\partial w} = \sum 2\,(y_i - w\,x_i - a)\cdot(-x_i)$$

aturan rantai lagi; kali ini turunan $(y_i - w{\cdot}x_i - a)$ terhadap w adalah $-x_i$

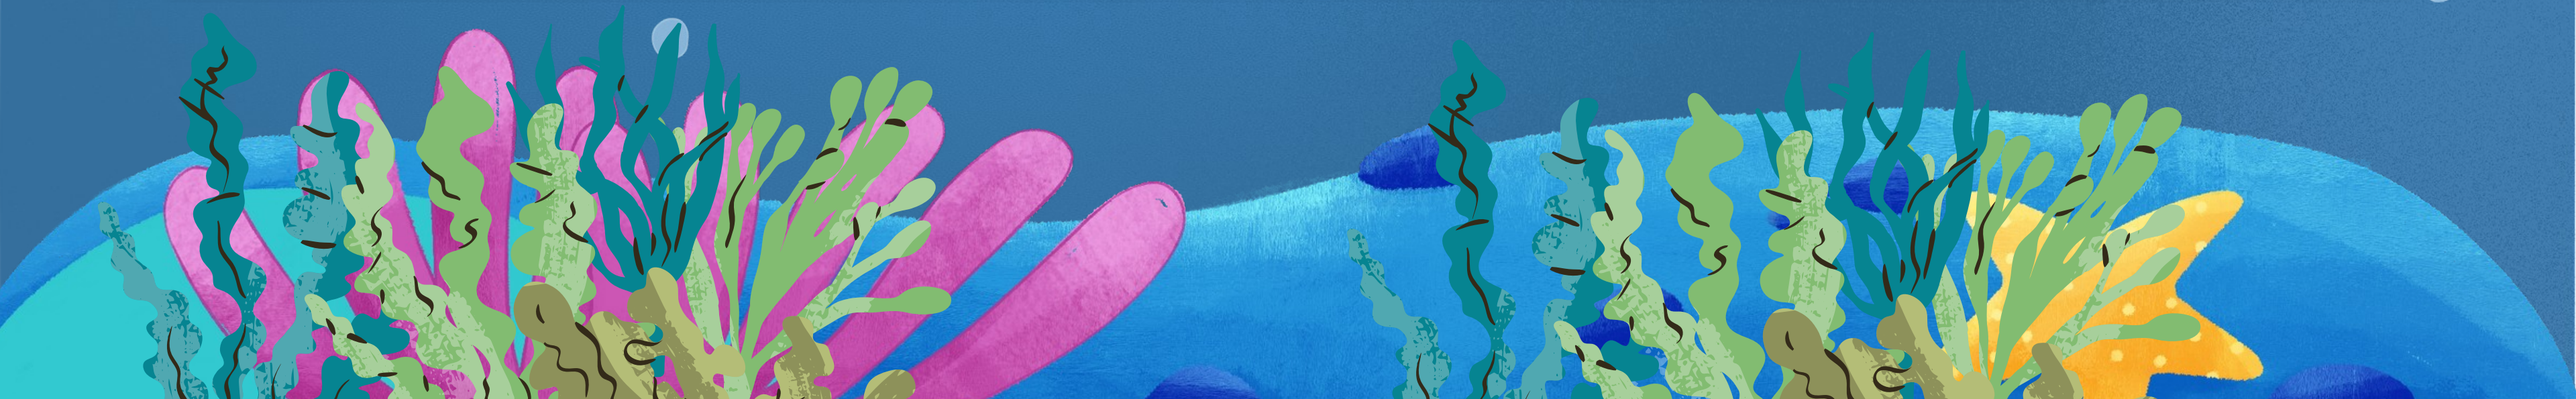
$$= -2\sum x_i\,(y_i - w\,x_i - a)$$

keluarkan konstanta −2: persamaan (5)

$$\sum x_i\,(y_i - w\,x_i - a) = 0$$

samakan dengan nol, lalu bagi dengan −2

Semua Σ berarti jumlah dari i = 1 sampai n.



LANGKAH 2

Masukkan â, selesaikan untuk w

$$\sum x_i (y_i - w x_i - \bar{y} + w \bar{x}) = 0$$

ganti a dengan persamaan (4)

$$\sum x_i [(y_i - \bar{y}) - w (x_i - \bar{x})] = 0$$

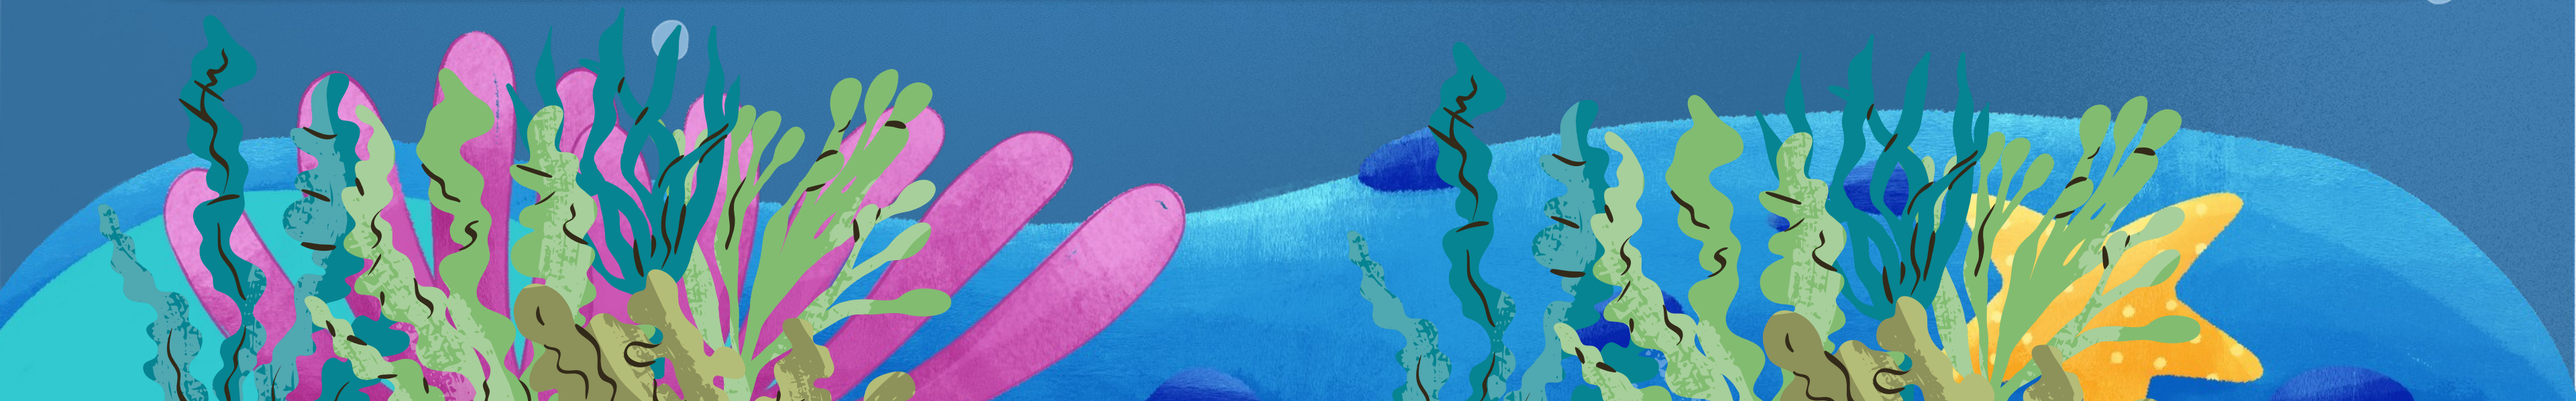
kelompokkan: suku dengan y, dan suku dengan w

$$\sum x_i (y_i - \bar{y}) - w \sum x_i (x_i - \bar{x}) = 0$$

pecah jumlahnya; w konstanta, jadi boleh keluar dari Σ

$$\hat{w} = \frac{\sum x_i (y_i - \bar{y})}{\sum x_i (x_i - \bar{x})}$$

pindahkan suku w ke ruas kanan, lalu bagi: persamaan (6)



LANGKAH 3

Merapikan (6) menjadi (7)

$$\sum(x_i - \bar{x}) = \sum x_i - n\bar{x} = 0 \qquad \sum(y_i - \bar{y}) = 0$$

selisih terhadap rata-rata selalu berjumlah nol

$$\sum x_i(y_i - \bar{y}) - \bar{x}\sum(y_i - \bar{y}) = \sum(x_i - \bar{x})(y_i - \bar{y})$$

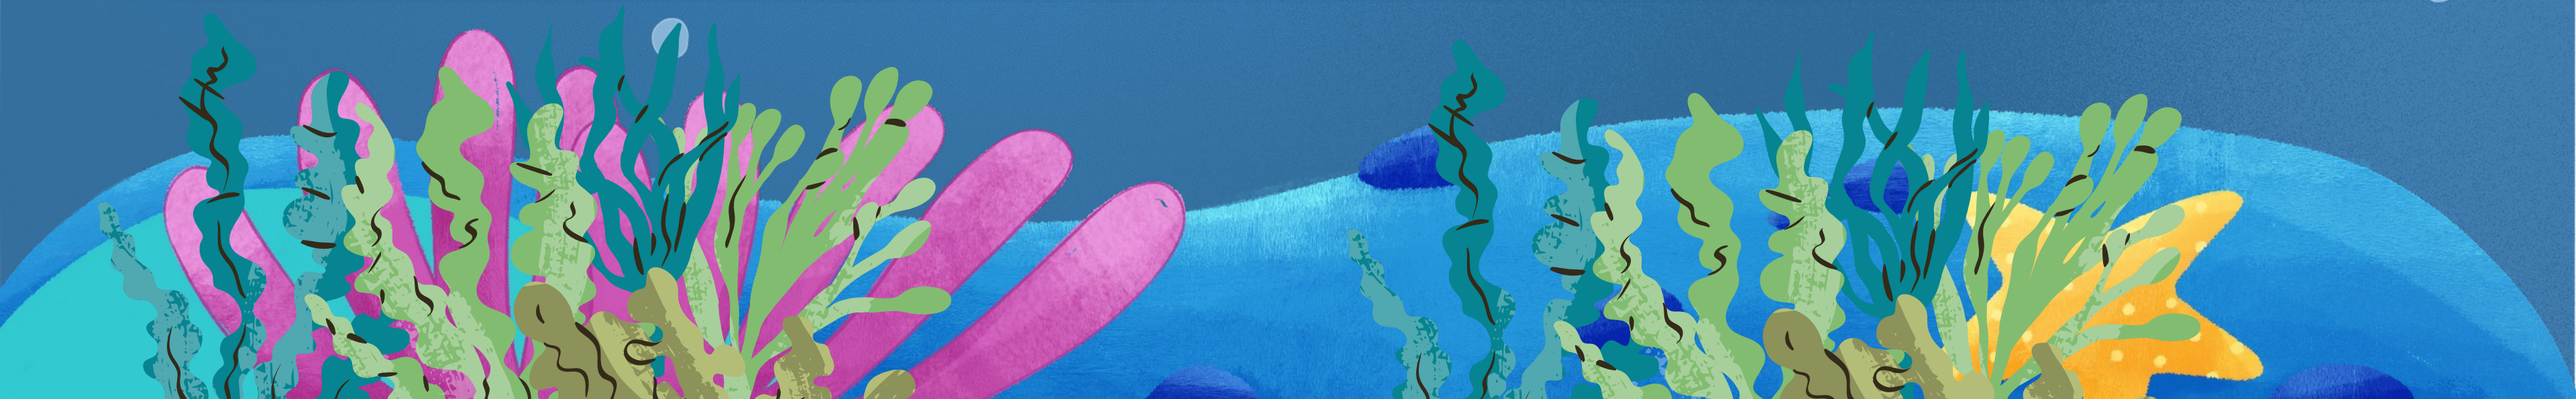
pembilang: kurangi dengan nol, nilainya tidak berubah

$$\sum x_i(x_i - \bar{x}) - \bar{x}\sum(x_i - \bar{x}) = \sum(x_i - \bar{x})^2$$

penyebut: cara yang sama

$$\hat{w} = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$$

persamaan (7): bentuk yang kita pakai untuk menghitung



HASIL

Rumus least squares

$$\hat{w} = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n} (x_i - \bar{x})^2}$$

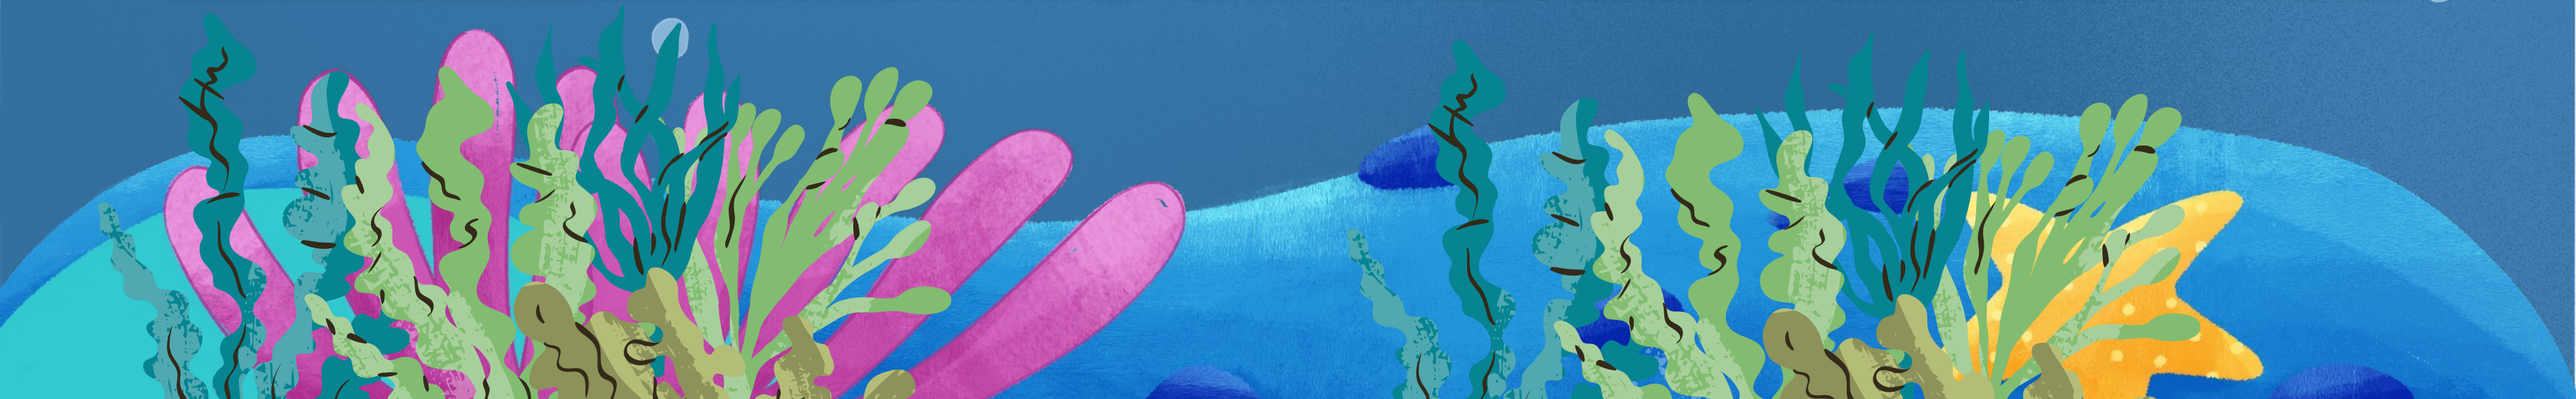
persamaan (7)

$$\hat{a} = \bar{y} - w\,\bar{x}$$

persamaan (4)

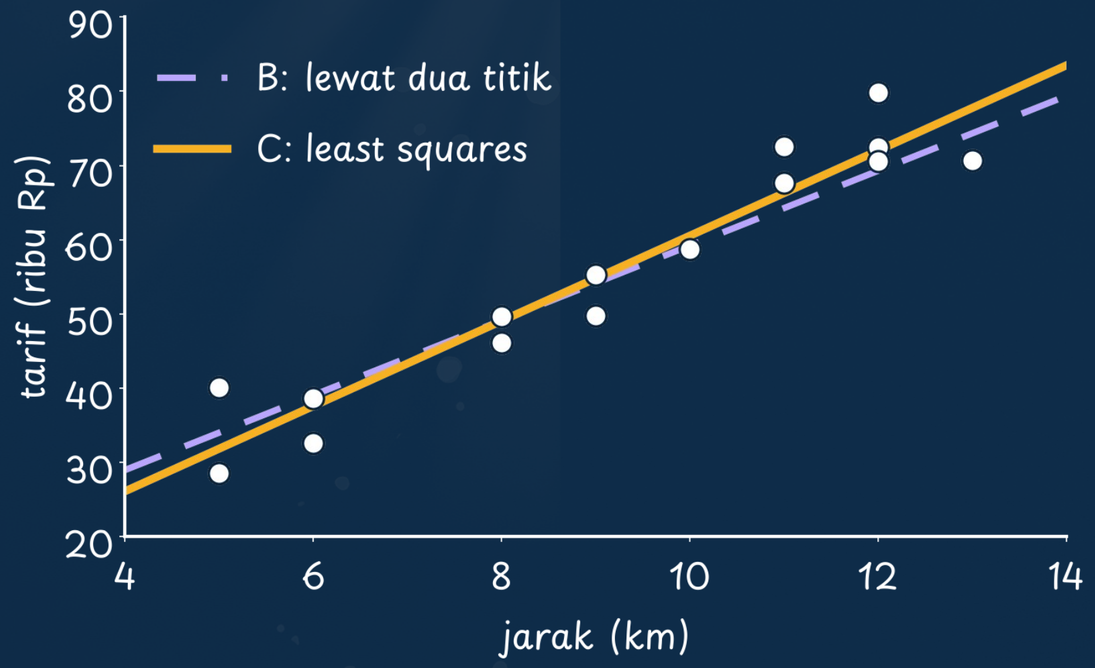
Urutan hitung: rata-rata x dan rata-rata y, lalu ŵ dengan (7), lalu â dengan (4).

Opsional di rumah: tunjukkan bahwa ŵ = cov(X, Y) / cov(X, X).



HASIL

Garis C adalah jawabannya



	Nilai
rata-rata x	9,13 km
rata-rata y	Rp55.553
$\hat{w}$	5.737,7
$\hat{a}$	3.148,8
RSS garis B	355.166.000
RSS least squares	296.861.703

Tidak ada garis lain dengan RSS lebih kecil

MAKNA

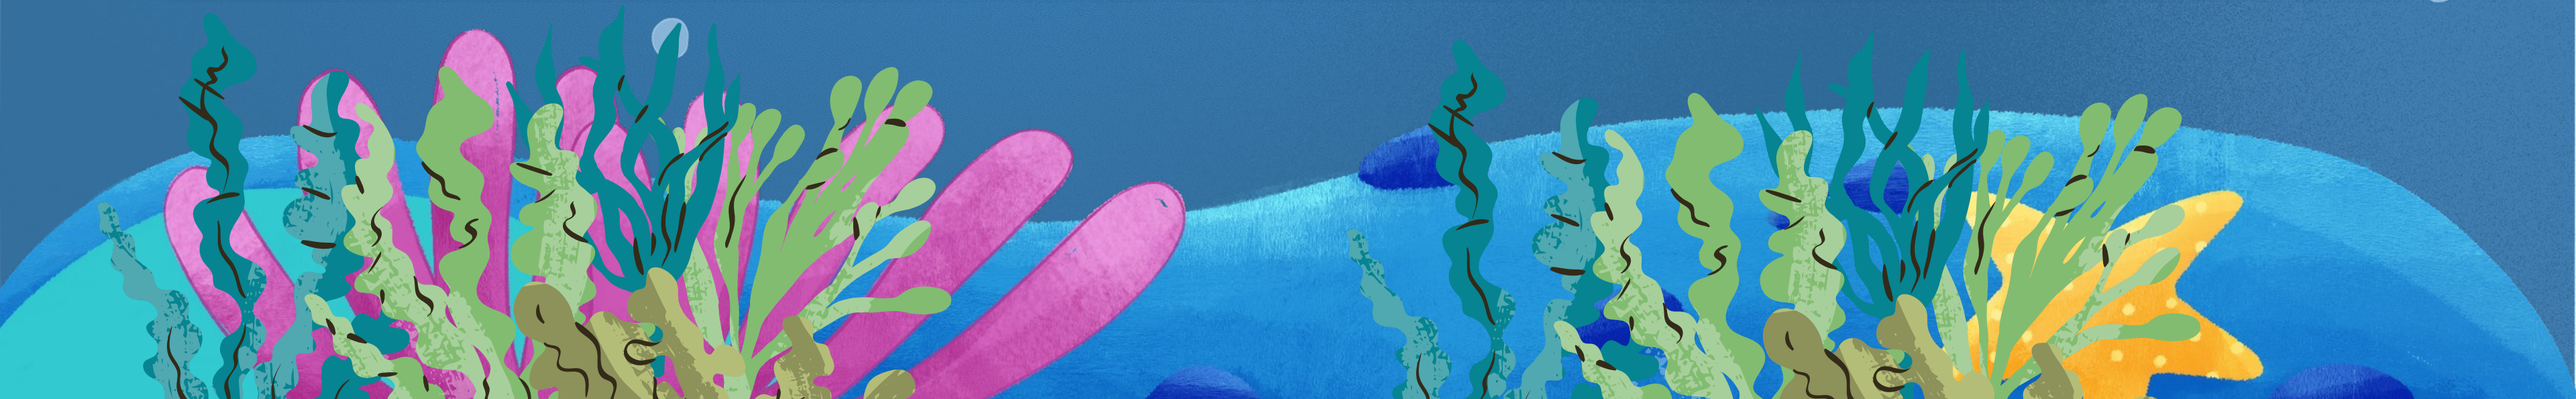
Membaca ŵ dan â

ŵ ≈ 5.738: setiap tambahan 1 km, tarif naik sekitar Rp5.738

â ≈ 3.149: tarif dasar menurut model

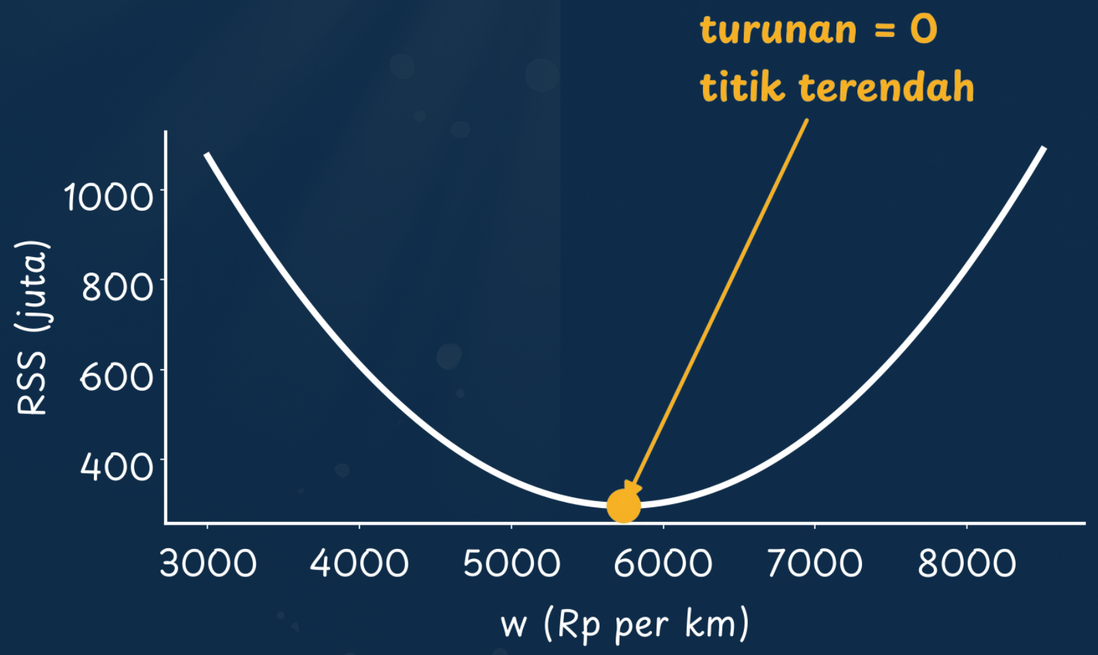
Prediksi 20 km: 5.737,7 × 20 + 3.148,8 ≈ Rp117.903

Hati-hati: data kita hanya 5 sampai 13 km. Makin jauh dari rentang itu, makin kurang bisa dipercaya.



MENGAPA MINIMUM?

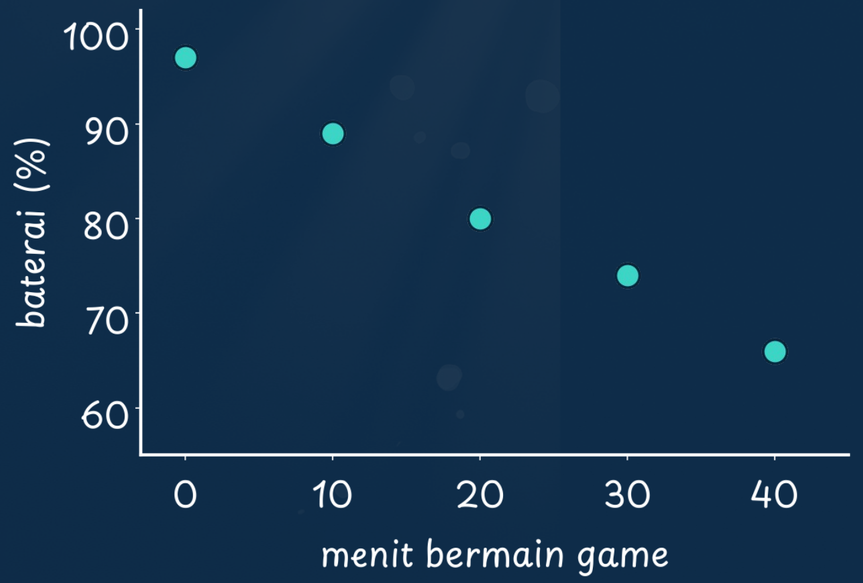
RSS berbentuk mangkuk



- RSS adalah jumlah kuadrat, jadi bentuknya mangkuk dengan satu dasar
- Turunan nol hanya terjadi di dasar itu
- **Bentuk ini muncul karena modelnya garis dan error-nya kuadrat**
- Model lain, misalnya otak komodo di Flappy Komodo, tidak punya rumus seperti ini

LATIHAN

Jam berapa HP-mu mati?



Menit (x)	Baterai (y)
0	97
10	89
20	80
30	74
40	66

Kali ini hubungannya negatif: makin lama main, makin sedikit baterai.

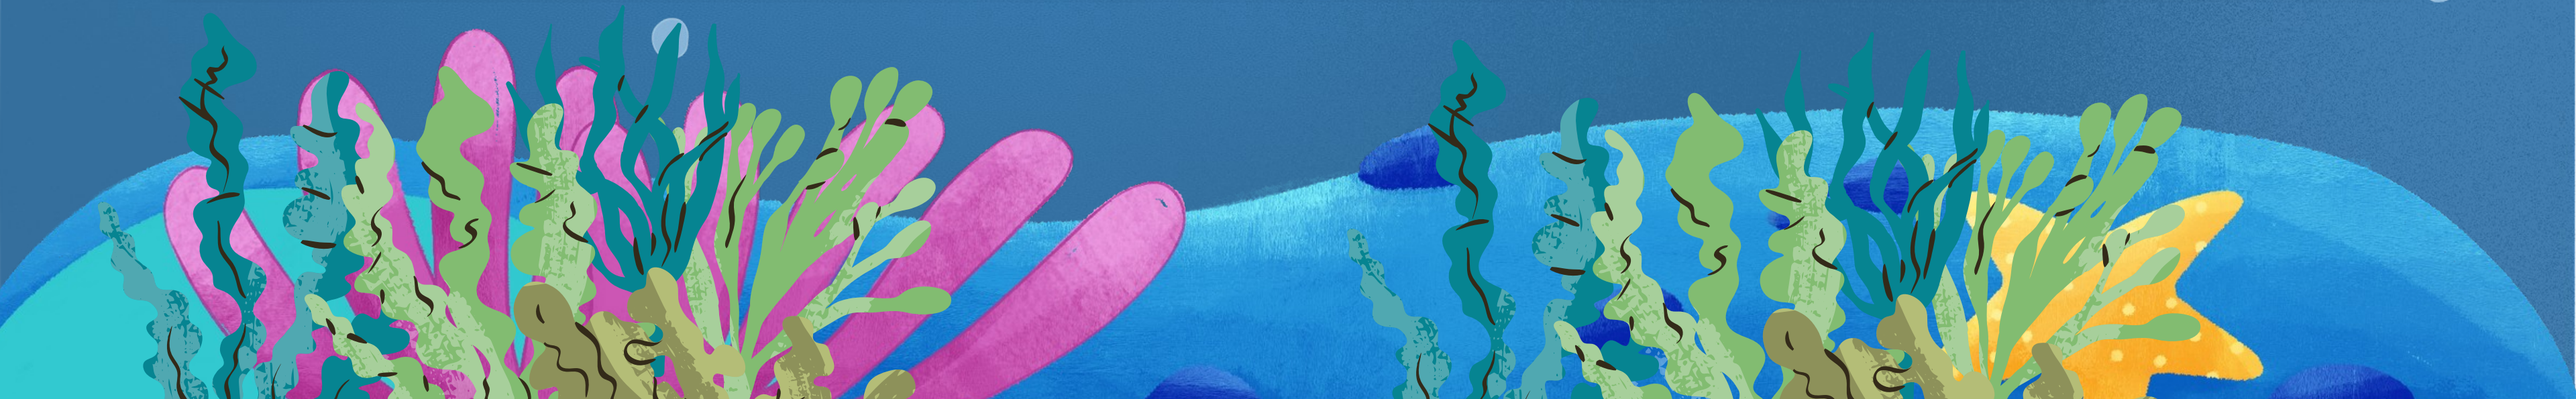
Data contoh untuk latihan

Bermain game di HP, baterai (%) dicatat setiap 10 menit.

Latihan 1 sampai 3: Kertas dan Kalkulator

1. Hitung rata-rata x dan rata-rata y, lalu $\hat{w}$ dengan (7) dan $\hat{a}$ dengan (4).
2. Hitung RSS garismu. Lalu hitung RSS garis yang lewat titik pertama dan terakhir. Mana yang lebih kecil?
3. Apa arti $\hat{w}$ dan $\hat{a}$ untuk baterai? Prediksi baterai setelah 60 menit. Kapan baterai habis ($\hat{y} = 0$)? Berapa prediksi setelah 180 menit, dan masuk akalkah?

Berpasangan · 25 menit · data ada di slide sebelumnya

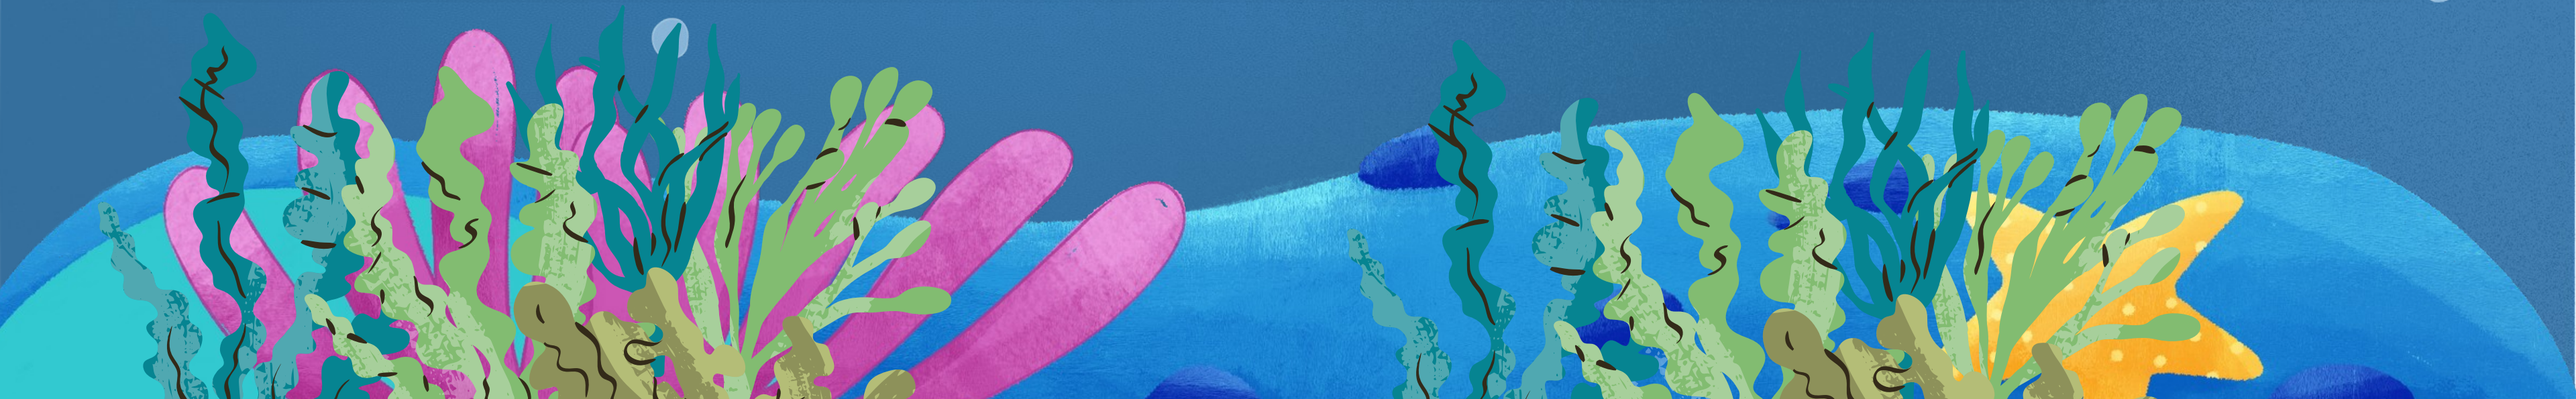


Latihan 4 dan 5: Colab

1. Tulis rumus least squares dalam Python murni. Jalankan pada 19 catatan baterai. Cocokkan dengan statistics.linear_regression.
2. Rusak rumusnya: (a) semua catatan diambil di menit yang sama, (b) satu angka salah ketik, 65 menjadi 6. Apa yang terjadi, dan mengapa?

Python murni: tanpa NumPy. Tautan Colab dibagikan mentor.

30 menit · bagian Python untuk programmer Go ada di awal notebook



DISKUSI

Mengapa hari ini cukup dengan rumus?

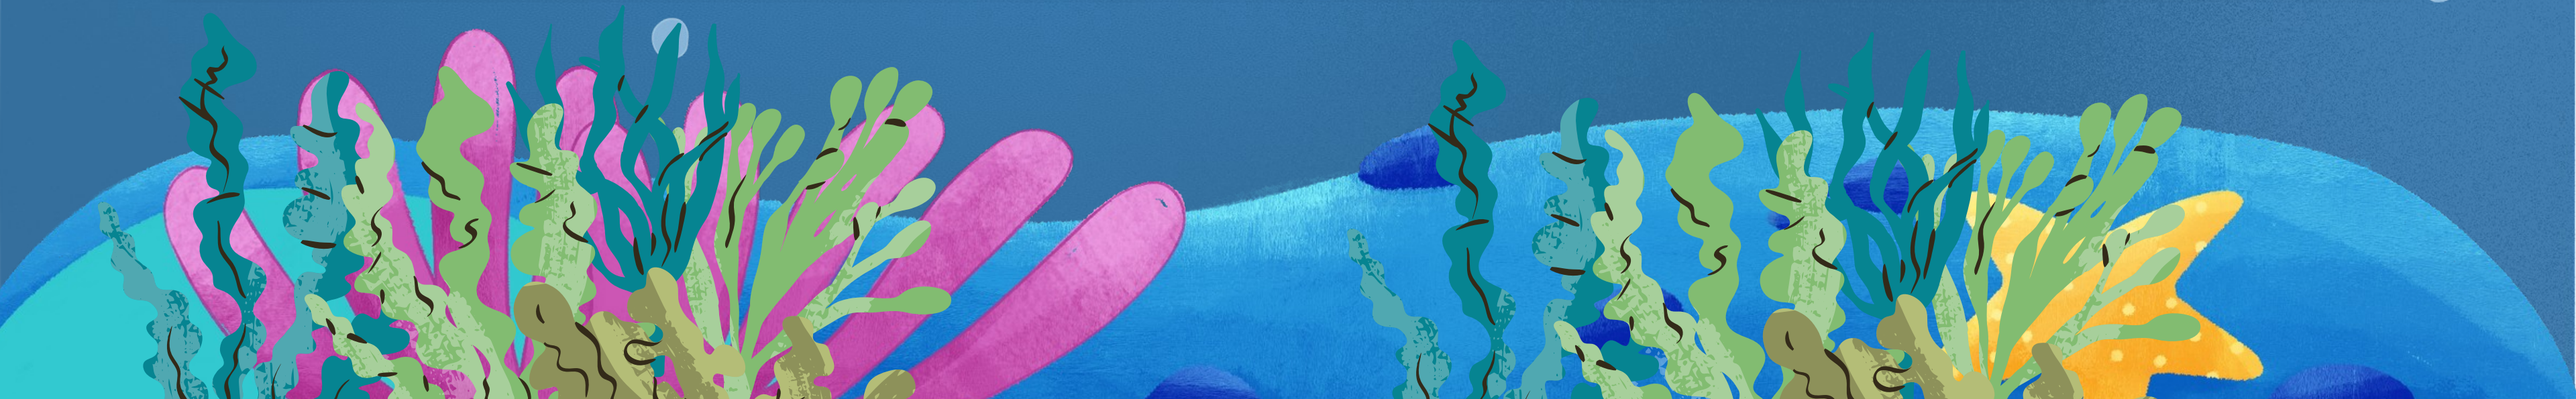
Pertanyaan

1. Apa yang membuat masalah ini bisa diselesaikan dengan satu rumus?
2. Satu salah ketik menggeser garis. Apa artinya bagi data nyata?
3. Bisakah rumus ini dipakai untuk melatih otak komodo di Flappy Komodo?

Pekan 1
garis + error kuadrat: ada rumus pasti

Pekan 2
tidak ada rumus, tetapi ada turunan: gradient descent

Pekan 9 sampai 12
tanpa turunan sama sekali: metaheuristik



Untuk Pertemuan 2

- Selesaikan notebook dan jawab dua pertanyaan pemahaman di akhirnya
- Baca UDL bagian 6.1 sampai 6.2 (halaman 77 sampai 85): gradient descent
- Opsional: tunjukkan $\hat{w} = \text{cov}(X, Y) / \text{cov}(X, X)$, dan UDL Problem 2.2 di akhir bab 2
- **Pekan depan: bagaimana mencari minimum jika tidak ada rumus?**

Advance Study Group

Terima Kasih



Sampai jumpa